

Fudan University

復旦大學

神经网络与深度学习 Project2

实验报告

方昱凯 23300180045

2026 年 6 月 1 日

1 任务一：Train a Network on CIFAR-10

1.1 数据集与 Baseline

模型结构：为了降低模型复杂度并节省训练时间，简化 ResNet-18 为 ResNet-10 作为 Baseline 模型，并针对 CIFAR-10 数据集对模型输入和输出进行对应调整




图 1: ResNet10 (Baseline) 结构图




图 2: BasicBlock 结构图

数据集及其划分： CIFAR-10 数据集，以官方提供的训练集作为训练集 (50000 个样本)，官方提供的测试集作为测试集 (10000 个样本)。对训练集样本进行数据增强 (RandomCrop + RandomHorizontalFlip)

实验设置： batch size=128;

学习率调度：cosine+warmup, lr=0.1, 前 5epoch 线性 warmup (0.01→1.0×lr), 之后 cosine 衰减;

优化器：SGD (momentum=0.9, weight decay=5e-4);

随机种子：42

epoch=100;

loss function：交叉熵损失函数 CrossEntropyLoss

激活函数：ReLU

训练可视化:




图 3: 训练曲线及测试曲线

训练结果: 经过 10epoch 训练后, 模型在官方测试集上的准确率达到 **95.13%**

图像经第一层卷积层后可视化:




图 4: 64 个通道分别展示




图 5: 64 个通道等比例混合与原图对比

发现第一层卷积成功将原图中图像的浅层特征信息（边缘、轮廓、条纹）提取出来，层数越高的卷积层提取的特征信息越详细

1.2 超参数分析

模型结构：以 ResNet-10 作为 Baseline 模型，ResNet-18 作为增加卷积层层数的对比试验，另外在 ResNet-10 的基础上对激活函数、损失函数、优化器建立网格搜索对比试验，比较不同搭配下模型的表现

数据集及其划分： CIFAR-10 数据集，以官方提供的训练集作为训练集（50000 个样本），官方提供的测试集作为测试集（10000 个样本）。对训练集样本进行数据增强（RandomCrop + RandomHorizontalFlip）

超参数搜索范围： 激活函数：ReLU/GELU；损失函数：标准交叉熵损失（CE） / 标签平滑交叉熵损失（label smooth）；优化器：SGD/AdamW

实验设置（所有实验相同）： batch size=128；

学习率调度：cosine+warmup, lr=0.1, 前 5epoch 线性 warmup ($0.01 \rightarrow 1.0 \times lr$), 之后 cosine 衰减；

随机种子：42

epoch=100；

训练可视化:




图 6: ResNet-18 对比试验训练曲线




图 7: ResNet-10 对比试验训练曲线

训练结果（按测试集准确率从高到低）：

实验配置	测试集准确率
ResNet-18 · SGD+CE+ReLU	95.13%
ResNet-10 · SGD+label smooth+ReLU	94.64%
ResNet-10 · SGD+CE+ReLU (Baseline)	94.18%
ResNet-10 · SGD+label smooth+GELU	94.04%
ResNet-10 · SGD+CE+GELU	93.56%
ResNet-10 · AdamW+label smooth+ReLU	93.52%
ResNet-10 · AdamW+label smooth+GELU	93.37%
ResNet-10 · AdamW+CE+GELU	92.98%
ResNet-10 · AdamW+CE+ReLU	92.81%

表 1: 训练结果表

总结：卷积层层数加深对模型性能提升最大，在测试集上表现最好（95.13%）。在模型结构相同时，通过改变损失函数、激活函数、优化器等超参数也会对模型的性能造成影响，可以一定程度上提升模型的性能，整体来看优化器选用 SGD 对优于 AdamW，损失函数 label smooth 优于 CE，激活函数影响不大。

2 任务二：Batch Normalization

2.1 VGG-A with and without BN

模型结构：VGG-A，针对 CIFAR-10 数据集对模型输入与输出做出调整；VGG-A-BN 在卷积层和激活函数之间添加 BatchNorm 层

数据集及其划分：CIFAR-10 数据集，以官方提供的训练集作为训练集（50000 个样本），官方提供的测试集作为测试集（10000 个样本）。对训练集样本进行数据增强（RandomCrop + RandomHorizontalFlip）

实验设置：batch size=128；

学习率调度：cosine+warmup, lr=0.1, 前 5epoch 线性 warmup ($0.01 \rightarrow 1.0 \times lr$), 之后 cosine 衰减；

优化器：SGD (momentum=0.9, weight decay=5e-4)；

随机种子: 2020

epoch=100;

loss function: 交叉熵损失函数 CrossEntropyLoss

激活函数: ReLU

训练可视化:




图 8: VGG-A 与 VGG-A-BN 训练对比

训练结果: 通过 100epoch 的训练, VGG-A 在测试集上准确率达到 91.78%, VGG-A-BN 在测试集上的准确率达到 91.92% (高出 VGG-A 0.66%), 对比训练过程发现, 添加了 BatchNorm 的 VGG-A 模型训练收敛更快, 并且在相同配置下, 最终模型的性能更优。

2.2 Loss Landscape

模型结构: VGG-A, 针对 CIFAR-10 数据集对模型输入与输出做出调整; VGG-A-BN 在卷积层和激活函数之间添加 BatchNorm 层

数据集及划分: CIFAR-10 数据集, 以官方提供的训练集作为训练集 (50000 个样本), 官方提供的测试集作为测试集 (10000 个样本)。对训练集样本进行数据增强 (RandomCrop + RandomHorizontalFlip)

实验设置: batch size=128;

学习率调度: cosine+warmup, 前 5epoch 线性 warmup ($0.01 \rightarrow 1.0 \times lr$), 之后 cosine 衰减;

优化器: SGD (momentum=0.9, weight decay= $5e-4$);

随机种子: 2020

epoch=20（为体现出 BatchNorm 对模型训练的加速以及训练过程稳定性的提升，故不考虑最终的模型性能，只训练 20epoch）；

loss function：交叉熵损失函数 CrossEntropyLoss

激活函数：ReLU

学习率选择：[0.1, 0.05, 0.01, 0.005]

Loss Landscape 可视化：横轴为 Train Step，纵轴为 Train Loss（四个学习率对应模型的最大和最小 Train Loss 组成 band）




图 9: VGG-A 有无 BN Loss Landscape 对比 (1)




图 10: VGG-A 有无 BN 对比 Loss Landscape (2)

分析：从上图可以看出，加入 Batch Normalization 的 VGG-A 模型训练的 Loss Landscape 带宽相对更窄，说明其对学习率变化的适应性更强，训练更平滑更稳定。并且有 BN 的模型训练前期的 loss 下降速度更快，说明 Batch Normalization 也有一定程度加速模型训练速度的作用。最终模型两个 loss 基本一致，说明 Batch Normalization 主要优势体现在对模型训

练平滑度的提升，虽然对最终结果精度有一定提升，但效果不明显。

2.3 gradient predictiveness (梯度可预测性)

概念解释：在参数空间中沿着当前梯度方向移动一定距离后，新的梯度位置的损失与原始梯度处损失+预测损失的差。如果梯度方向稳定（可预测），那么经过步长移动，两者变化应该较小。

衡量指标：在模型训练过程中的一点，取当前梯度 g 的下降方向 $\frac{g}{\|g\|}$ ，以步长 α 更新参数为 $\theta_\alpha = \theta + \alpha \frac{g}{\|g\|}$ ，在新参数位置计算损失函数 $L(\theta_\alpha)$ ，度量 $\frac{|L(\theta_\alpha) - L(\theta) - \alpha \|g\|}{L(\theta)}$ ，越小，说明两处梯度下降方向越相似（可预测），模型训练过程越稳定。

gradient predictiveness 可视化：




图 11: VGG-A 有无 BN gradient predictiveness 对比

分析：从上图可以看出，加入 Batch Normalization 的 VGG-A 模型训练过程中，衡量指标 $\frac{|L(\theta_\alpha) - L(\theta) - \alpha \|g\|}{L(\theta)}$ 低于没有 Batch Normalization 的 VGG-A 模型。由此可见加入 Batch Normalization 后，模型训练的梯度可预测性更强。

2.4 Maximum difference in gradient over the distance (梯度变化的最大差异)

概念解释：这个指标是指在参数空间中，沿某个方向（通常是梯度方向）移动一段距离 d 的范围内，梯度变化的最大差异。

衡量指标：在模型训练过程中的一点，取当前梯度 g 的下降方向 $\frac{g}{\|g\|}$ ，以步长 t 更新参数，在新参数位置计算梯度 g_t ，度量两处梯度的 L_2 差异 $\|g_t - g\|$ ，在不同步长 t 中取最大值，最大值越小，表示模型训练梯度变化越平滑。

Maximum difference in gradient over the distance 可视化：




图 12: VGG-A 有无 BN Maximum difference in gradient over the distance 对比

分析：从上图可以看出，加入 Batch Normalization 的 VGG-A 模型训练过程中，衡量指标 $\|g_t - g\|$ 在不同步长下曲线变化较缓，并且最大值（1.436）低于未加入 Batch Normalization 的 VGG-A 模型（3.389）。由此可见，由此可见加入 Batch Normalization 后，模型训练的梯度变化更平滑。

3 代码仓库及模型权重下载地址

- 代码仓库: https://github.com/FYK2004/Neural_Network_PJ2

- 模型权重下载地址:

https://drive.google.com/drive/folders/1HFcDPD_3GM4KMk89z4ccqVTMlSCib1Va?usp=drive_link